

Laboratorio 01: Noticias delictuales, Gemini y Obsidian

Asignatura: *Machine Learning* (2026-02)

Profesor: Dr. Juan Bekios Calfa

Ignacia Belén Peña Velásquez

Escuela de Ingeniería

Universidad Católica del Norte

Ingeniería Civil Industrial

ignacia.pena@alumnos.ucn.cl

Francisco Cortés

Escuela de Ingeniería

Universidad Católica del Norte

Ingeniería Civil Industrial

francisco.cortes07@alumnos.ucn.cl

Resumen—El laboratorio consistió en transformar noticias delictuales publicadas en Internet en una estructura que pudiera revisarse, validarse y navegarse en Obsidian. Se trabajó con 12 noticias de la Región de Coquimbo y se implementó el flujo completo: captura, limpieza, extracción con Gemini, validación del JSON, generación de notas Markdown y Data Understanding. La versión final obtuvo 12 JSON válidos y 0 fallidos. También se revisaron manualmente las 12 noticias. Esa revisión fue importante porque permitió encontrar problemas que una validación puramente sintáctica no detectaba, como contenido de “Lee también”, tribunales clasificados como lugares o relaciones que podían perder la presunción indicada en la noticia. El resultado final corresponde a una base de conocimiento documental; no pretende reemplazar estadísticas oficiales ni determinar culpabilidad.

Index Terms—Gemini, extracción estructurada, JSON, Obsidian, grafo de conocimiento, Data Understanding, trazabilidad.

I. INTRODUCCIÓN

La información de una noticia es fácil de leer para una persona, pero no necesariamente está preparada para comparar casos o seguir relaciones entre entidades. En este laboratorio el problema se abordó pensando en un **analista de información delictual**: el objetivo no fue acumular artículos, sino convertirlos en conocimiento consultable manteniendo siempre el vínculo con la fuente original [1].

El alcance se fijó en noticias publicadas durante 2026 relacionadas con la Región de Coquimbo. Las fuentes del corpus semilla fueron Cooperativa y BioBioChile. Se trabajó con 12 noticias porque el propósito del laboratorio era comprobar el pipeline completo y poder revisar manualmente una muestra suficiente; no se buscó construir una base estadística representativa de la delincuencia regional.

Se definió como relación útil un vínculo explícito dentro de la noticia o una entidad compartida entre documentos: mismo delito, persona, organización o lugar. No se utilizó clustering. Cuando un dato no aparecía, se dejó como `null` o lista vacía. Además, se mantuvo una distinción estricta entre detenido, imputado, sospechoso, víctima y otras condiciones, ya que ninguna de ellas equivale automáticamente a culpabilidad.

Las herramientas principales fueron Python 3.12, requests, BeautifulSoup, pandas, matplotlib,

Pydantic, el SDK google-genai, Conda, GitHub Actions y Obsidian.

II. MARCO TEÓRICO

El trabajo sigue la adaptación de CRISP-DM planteada para el laboratorio: comprensión del problema, comprensión y preparación de los datos, extracción mediante LLM, validación del JSON, generación del conocimiento en Obsidian y evaluación crítica del resultado [1]. En este caso el LLM no se considera la fuente de verdad. Su función es proponer una estructura a partir del texto; posteriormente el código verifica esa estructura y la auditoría humana revisa el significado.

Para reducir respuestas libres se usó salida estructurada. Gemini recibe el texto limpio y un esquema basado en Pydantic, de modo que la respuesta debe ajustarse al JSON esperado. Este enfoque es compatible con la documentación oficial de Gemini sobre *structured outputs* [2]. Aun así, un JSON válido puede contener una interpretación discutible; por eso se separaron la validación estructural y la revisión semántica.

La persistencia final no es una base SQL. Cada noticia y cada entidad relevante se guarda como Markdown y se conecta mediante enlaces internos de Obsidian. El grafo resultante sirve para navegar menciones y coapariciones; que dos noticias compartan una entidad no demuestra una relación causal entre los hechos.

III. METODOLOGÍA

III-A. Business Understanding y modelo de conocimiento

Antes de llamar a Gemini se definieron usuario, alcance, fuentes, entidades y reglas. Las entidades usadas fueron Noticia, Delito, Persona, Organización, Lugar, Objeto y Relación. De acuerdo con el modelo entregado por el profesor, tribunales, fiscalías e instituciones policiales se clasifican como **organizaciones**; comunas, ciudades, regiones y puntos geográficos se clasifican como **lugares** [1].

El contrato JSON incluye `id_noticia`, título, fecha, fuente, URL, resumen, delitos, personas, organizaciones, lugares, objetos y relaciones. Cada persona conserva nombre y rol; cada objeto usa tipo, nombre, cantidad y

unidad; las relaciones usan origen, tipo y destino. El esquema completo y sus reglas quedaron documentados en docs/esquema_json.md.

III-B. Adquisición y preparación

Cada noticia mantiene un ID estable NXXX. La captura usa `requests.Session`, `timeout`, `User-Agent` identificable, redirecciones y pausas. Los adaptadores de fuente localizan el artículo y el limpiador elimina `script`, `style`, navegación, pie de página, recomendaciones y repeticiones.

Durante las primeras pruebas aparecieron dos errores concretos. Primero, algunas fechas de Cooperativa no se recuperaban por un patrón de URL mal escapado. Segundo, en BioBioChile una tarjeta “Lee también” podía quedar dentro del contenido y contaminar la noticia siguiente. Ambos problemas se corrigieron y se agregaron pruebas específicas para evitar regresiones.

III-C. Extracción con Gemini y validación

La ejecución final fijó el modelo mediante la variable `GEMINI_MODEL=gemini-3.5-flash-lite`. El prompt exige extraer solo contenido explícito, devolver JSON, mantener la incertidumbre de expresiones como “presunto” o “habría” y no transformar una valorización monetaria en dinero incautado.

Después de Gemini se aplica un postproceso conservador. Este elimina duplicados exactos, reclasifica juzgados y tribunales como organizaciones, descarta referencias policiales genéricas tratadas erróneamente como personas y elimina relaciones con extremos inexistentes. También se descartan relaciones que transformen a una persona detenida, imputada o sospechosa en autora afirmativa del delito sin respaldo explícito. Si una relación de “vinculación” termina en un lugar físico por error del LLM, se elimina en vez de reinterpretarla.

Finalmente, `ValidadorJSON` verifica campos, tipos, ID, URL, fuente y estructura de personas, objetos y relaciones. De este modo la etapa de validación no depende de que Gemini “se corrija a sí mismo”.

III-D. Obsidian y trazabilidad

Los JSON válidos generan notas en Noticias/, Delitos/, Personas/, Organizaciones/, Lugares/, Objetos/ y Relaciones/. Las conexiones se escriben con `[[wikilinks]]` y el propio proyecto revisa que no existan enlaces rotos.

La trazabilidad se mantiene de extremo a extremo. Por ejemplo, durante la ejecución N005 sigue las rutas `data/urls.csv`, `data/raw/N005.html`, `data/processed/N005.txt`, `data/json/N005.json`, `data/validation/N005.validation.json` y `obsidian_vault/Noticias/N005.md`. El HTML RAW se conserva en el artifact del workflow, mientras que el texto procesado, JSON, validación y notas de Obsidian quedan versionados en el repositorio. Así se mantiene capacidad de auditoría sin publicar como archivos ordinarios una copia completa del contenido periodístico. La matriz completa para N001–N012 quedó en docs/trazabilidad.md.

Tabla I: Indicadores principales de la ejecución final.

Indicador	Resultado
Noticias procesadas	12
JSON válidos / fallidos	12 / 0
Relaciones extraídas	38
Personas / organizaciones únicas	36 / 26
Archivos Markdown	185
Enlaces rotos	0
Pruebas automatizadas	19/19
Auditoría manual	12/12




Figura 1: Noticias por fuente. Fuente: elaboración propia a partir de los JSON validados del run #14.

III-E. Data Understanding y auditoría

Una vez generado el corpus estructurado se calcularon noticias por fuente, delitos frecuentes, lugares frecuentes, menciones delito–lugar, cantidad de personas y organizaciones por noticia, porcentaje de campos ausentes y evolución temporal. También se revisaron duplicados, JSON inválidos, variantes nominales y relaciones problemáticas.

La revisión manual cubrió las 12 noticias. Para cada caso se contrastó la fuente con el texto procesado, el JSON y la nota generada. Esta etapa se mantuvo separada de los tests: los tests comprueban comportamiento del código; la auditoría revisa si el significado extraído sigue siendo defendible.

IV. RESULTADOS

La ejecución final corresponde a GitHub Actions, run #14, con estado **SUCCESS**. Se procesaron 12 noticias; 8 pertenecen a Cooperativa y 4 a BioBioChile. Se obtuvieron 12 JSON válidos, 0 fallidos y 0 JSON estructuralmente inválidos. El conjunto final contiene 38 relaciones, 36 personas únicas y 26 organizaciones únicas. La bóveda quedó con 185 archivos Markdown y 0 enlaces rotos. Las pruebas automatizadas finalizaron con 19/19 casos aprobados.

La Fig. 1 muestra una muestra desbalanceada por medio: dos tercios del corpus provienen de Cooperativa. Esta diferencia debe considerarse al interpretar el resto de los gráficos, porque describe cobertura periodística, no incidencia delictual.

En la Fig. 2, homicidio es el delito más repetido con 6 noticias y tráfico de drogas aparece en 3. El resultado depende directamente del corpus seleccionado y no se interpreta como una tasa regional.



Figura 2: Delitos mencionados con mayor frecuencia. Fuente: elaboración propia, run #14.




Figura 3: Lugares más mencionados después de separar tribunales e instituciones. Fuente: elaboración propia, run #14.




Figura 4: Co-menciones de delitos y lugares dentro de una misma noticia. Fuente: elaboración propia, run #14.

La corrección del modelo de entidades evita mezclar juzgados o tribunales con comunas. En la Fig. 3 los primeros lugares corresponden a referencias geográficas del corpus; esto hace que el gráfico responda mejor a la pregunta “¿dónde se mencionan los hechos?”.

La Fig. 4 sirve para explorar qué delitos aparecen junto a determinados lugares. La co-mención no demuestra que un lugar tenga mayor riesgo ni que exista una relación causal;




Figura 5: Personas y organizaciones extraídas por noticia. Fuente: elaboración propia, run #14.




Figura 6: Porcentaje de noticias con campos estructurales ausentes. Fuente: elaboración propia, run #14.

solamente resume el contenido de las noticias procesadas.

La Fig. 5 permite detectar noticias con alta densidad de entidades, como operativos con varias instituciones, y otras donde la fuente publica pocos nombres. Por tanto, una barra baja no significa que falten datos obligatoriamente; puede reflejar una redacción periodística más reservada.

Los campos `objetos` y `relaciones` presentan el mayor porcentaje de ausencia, ambos con 8,33 %. En este proyecto una lista vacía no se considera automáticamente un error: si una noticia no menciona un arma, sustancia, vehículo u objeto relevante, es preferible mantener `[]` antes que completar el dato por inferencia.

La Fig. 7 muestra cuándo se publicaron las noticias seleccionadas. Con solo 12 registros no es válido hablar de tendencia criminal; el gráfico se usa para revisar cobertura temporal y comprobar que las fechas fueron recuperadas de manera consistente.

En calidad de datos se registraron 0 noticias duplicadas, 0 JSON inválidos y 1 grupo(s) de variantes nominales. Después de los controles automáticos no quedaron relaciones con extremos no trazables. La auditoría manual se mantuvo como una segunda capa, porque una relación puede ser estructuralmente válida y aun así necesitar contexto.

V. DISCUSIÓN

Los errores encontrados durante el desarrollo fueron útiles para entender dónde falla realmente este tipo de pipeline. El




Figura 7: Distribución temporal de las noticias del corpus. Fuente: elaboración propia, run #14.

caso de “Lee también” mostró que una limpieza aparentemente correcta puede incorporar texto que sí pertenece al sitio, pero no a la noticia analizada. Algo parecido ocurrió con la clasificación de un Juzgado de Garantía: el nombre puede referirse a un edificio físico, pero el modelo de conocimiento del laboratorio define tribunales como organizaciones. Se corrigió esa regla antes de regenerar los análisis.

También se revisaron N007 y N010 porque en una versión anterior aparecían relaciones que, aunque cumplían la forma del JSON, simplificaban demasiado el significado. En N007 se descartó una “vinculación” cuyo destino era una cárcel en vez de la red u organización a la que hacía referencia el texto. En N010 se eliminaron relaciones afirmativas de agresión o uso de arma cuando la persona estaba descrita como imputada y la noticia mantenía expresiones de incertidumbre. En ambos casos se prefirió perder una relación antes que fortalecer una acusación.

El principal límite que sigue presente es la correferencia. Un mismo individuo puede aparecer como “un hombre”, “el sujeto” o “el imputado”. Se evitó fusionar estas expresiones automáticamente porque un criterio demasiado agresivo puede unir personas distintas. Para un trabajo de mayor escala sería necesario construir un conjunto anotado manualmente y medir precisión y recall por entidad y relación.

VI. CONCLUSIONES

El laboratorio permitió completar el flujo solicitado desde una noticia pública hasta una red de notas navegables. La parte más útil no fue solamente obtener JSON, sino comprobar que la calidad depende de varias capas: limpieza, esquema, validación, reglas conservadoras, trazabilidad y revisión humana.

La versión final procesa las 12 noticias sin fallos estructurales, genera el vault sin enlaces rotos y deja evidencia reproducible de pruebas, entorno y resultados. Aun así, las estadísticas obtenidas deben leerse como características de este corpus y no como información oficial sobre delincuencia. Como continuación natural sería conveniente ampliar el corpus solo después de disponer de un conjunto de referencia anotado, de modo que la calidad del extractor pueda medirse y no solo inspeccionarse.

VII. CÓDIGO Y REPRODUCIBILIDAD

El proyecto se organiza con `main.py` como orquestador y módulos dentro de `src/` para adquisición, limpieza, extracción, validación, conocimiento y análisis. El entorno se define en `environment.yml`; no se utiliza `requirements.txt`. La clave de Gemini permanece fuera del repositorio y GitHub Actions la obtiene desde `secrets.GEMINI_API_KEY`.

El run final registra el commit, versiones de Python y librerías, modelo Gemini y número de ejecución en `outputs/environment_runtime.txt`. La configuración usada fue Python 3.12.14, google-genai 2.25.0 y gemini-3.5-flash-lite. Los resultados de las pruebas quedan en `outputs/test_results.txt`; la auditoría completa está en `docs/auditoria_manual_final.md` y la matriz de trazabilidad en `docs/trazabilidad.md`.

VII-A. Automatización y trazabilidad técnica

GitHub Actions se utilizó como mecanismo de integración continua y reproducibilidad. El workflow `lab01_pipeline.yml` ejecuta el pipeline y publica las salidas estructuradas; `report_compile.yml` compila y publica el PDF del informe. Por diseño, cuando un workflow materializa y versiona un artefacto, GitHub registra técnicamente a `github-actions[bot]` como autor y `committer` de ese commit. Durante la preparación inicial del repositorio también se utilizaron automatizaciones de integración, por lo que el historial conserva otros commits de esa cuenta de servicio.

La identidad `github-actions[bot]` identifica el proceso automático de GitHub y no un integrante adicional del equipo ni una fuente de información del corpus. El run #14 del pipeline fue activado por la cuenta IgnaciaPV, ejecutó el commit `a56119a0f1fab19fc65a792ea7058c7f499c4d60` y finalizó con estado **SUCCESS**. El historial se conserva sin reescritura para que la procedencia de las ejecuciones y de los artefactos automáticos siga siendo verificable.

```
conda env create -f environment.yml
conda activate lab-noticias-obsidian
python main.py capturar --forzar
python main.py extraer --forzar
python main.py obsidian
python main.py analizar
python main.py auditar
python -m unittest discover -s tests -v
```

Código 1: Ejecución del corpus semilla

El repositorio de trabajo es <https://github.com/IgnaciaPV/Machine-Learning>. Al momento de preparar la entrega se mantiene privado, por lo que el profesor debe tener acceso como colaborador o recibir el paquete completo de evidencia.

APÉNDICE A

AUDITORÍA MANUAL N001–N012

APÉNDICE B

PAUTA OFICIAL Y AUTOEVALUACIÓN

La pauta propuesta en la presentación del laboratorio distribuye la evaluación en siete criterios [1]. La tabla no

Tabla II: Resumen de la revisión manual del corpus final.

ID	Estado	Revisión realizada
N001	Con observación	Se mantuvieron el detenido, Río Elqui y los jarabes. Se eliminaron referencias policiales genéricas tratadas como personas y se anuló la valorización como cantidad física. Persisten correferencias del detenido.
N002	Conforme	Robo de camioneta, víctima, persecución y detenidos se mantienen sin agregar delitos adicionales.
N003	Con observación	Se distinguen los dos homicidios y se conserva la condición de presunta autora. Persisten algunas correferencias descriptivas.
N004	Conforme	Los delitos imputados se mantienen como tales; el postproceso impide convertir la detención en afirmación de culpabilidad.
N005	Conforme	Homicidio, víctima, arma y presunto autor quedan respaldados; el Juzgado de Garantía se clasifica como organización.
N006	Conforme	Se conservan víctima, captura y objetos incautados sin generar una relación afirmativa de autoría.
N007	Corregido	Se mantienen los cinco gendarmes y los delitos investigados. Se eliminó la relación de vinculación que apuntaba erróneamente a una cárcel como destino semántico.
N008	Conforme	El JSON indica que la víctima fue hallada en un pozo y que el caso se investiga como homicidio, sin afirmar que el pozo sea el lugar de ejecución.
N009	Conforme	Se mantienen víctima, terminal, arma y tercer sujeto sin inventar la identidad del autor.
N010	Corregido	Se conserva PRESUNTO_AUTOR_DE; se descartaron relaciones afirmativas de agresión/uso de arma que podían borrar la incertidumbre de la noticia.
N011	Conforme	La limpieza ya no incorpora la noticia recomendada del bloque “Lee también”.
N012	Conforme	Se conservan los dos detenidos y los antecedentes delictuales mencionados; el Tribunal de Garantía se trata como organización.

asigna una nota; únicamente indica dónde se encuentra la evidencia para que el criterio pueda revisarse.

Tabla III: Trazabilidad de la pauta de evaluación.

Criterio	Peso	Evidencia
Business Understanding y alcance	10 %	Sec. I y III-A
Modelo de conocimiento y JSON	15 %	III-A, esquema
Adquisición y limpieza	15 %	III-B, tests
Gemini y validación	20 %	III-C, JSON
Vault de Obsidian	20 %	III-D, vault
Data Understanding	10 %	Figs. 1–7
Crítica, ética y reproducibilidad	10 %	V–VII, auditoría

REFERENCIAS

[1] J. Bekios Calfa, “Laboratorio: Noticias delictuales, LLM y Obsidian - De texto no estructurado a grafo de conocimiento,” material de Machine Learning, Universidad Católica del Norte, 2026.

[2] Google, “Structured outputs - Gemini API,” Google AI for Developers, documentación consultada para la implementación del laboratorio, 2026. [En línea]. Disponible: <https://ai.google.dev/gemini-api/docs/structured-output>

[3] Google, “Interactions API - Gemini API,” Google AI for Developers, documentación consultada para la implementación del laboratorio, 2026. [En línea]. Disponible: <https://ai.google.dev/gemini-api/docs/interactions-overview>

APÉNDICE C

EVIDENCIA DE EJECUCIÓN

La ejecución que respalda las cifras del informe quedó registrada de forma automática, sin incluir secretos. Esto permite diferenciar los resultados del corpus de una descripción escrita posteriormente.

Tabla IV: Metadatos del entorno final.

Elemento	Valor
GitHub Actions	run #14 (ID 36354954389)
Commit de entrada	a56119a0f1fa...
Python	3.12.14
google-genai	2.25.0
Modelo	gemini-3.5-flash-lite
Captura / limpieza	12 / 12
JSON válidos / fallidos	12 / 0
Pruebas	19 / 19
Vault	185 Markdown; 0 enlaces rotos

Como comprobación rápida de trazabilidad, N005 conserva la secuencia data/processed/N005.txt → data/json/N005.json → data/validation/N005.validation.json → obsidian_vault/Noticias/N005.md. Los 12 textos procesados se incluyen en el repositorio final; el HTML RAW y la respuesta cruda del LLM permanecen en el artifact de GitHub Actions para no convertir el repositorio en una copia masiva de contenido periodístico.